

송희웅

+821030982011 @kofsitho@naver.com

소프트웨어 개발자로서 웹 개발 전문성을 바탕으로 최근에는 LLM과 AI 기술을 활용한 제품 개발에 깊은 관심과 열정을 가지고 있습니다.

Langchain, RAG, Langgraph, Livekit(Voice Agent) 등 최신 LLM 기술을 활용한 AI 서비스 개발 경험을 보유하고 있으며, 특히 Claude, GPT 등 다양한 LLM을 활용한 실제 프로덕션 경험을 통해 AI 기반 서비스의 설계와 구현 능력을 갖추고 있습니다.

풀스택 개발 경험을 토대로 AI 솔루션의 프론트엔드부터 백엔드까지 전반적인 아키텍처 설계와 구현이 가능합니다.

경력 9년 7개월



와이즈에이아이

2025.03 - 재직중 (1년 1개월) | 정규직 | AI 엔지니어 | 센터장

병원 고객상담 Agent 개발 및 배포

2025.03 - 2025.05

의료기관(치과/병원) 고객 상담 자동화를 위한 AI 기반 대화형 에이전트 시스템 개발 및 AWS 클라우드 환경 배포, NextJS 기반 Agent 모니터링 웹 대시보드 구축

1. LangGraph 기반 AI Agent 아키텍처 설계 및 개발

성과: Langgraph Agent 기반 대화 상태 관리 시스템 구축으로 95% 이상의 정확한 고객 상담 응답 달성

역할: LangGraph를 활용한 에이전트 워크플로우 설계 및 구현

기술: LangGraph Platform API(Redis, PostgreSQL), LLM: GPT/Claude, Python

2. 웹사이트 크롤링 및 데이터 추출 시스템 개발

성과: 웹사이트 텍스트를 6개 토픽으로 자동 분류 및 구조화된 데이터 추출 시스템 구현

역할: TrustCall 기반 정보 추출 워크플로우 설계 및 대규모 텍스트 청킹 알고리즘 개발

기여: 토픽별 구조화된 스키마 정의 및 결과 통합 로직 구현으로 90% 이상의 정보 추출 정확도 달성

기술: Crawl4ai, LangGraph, Langchain-TrustCall, Pydantic

3. FastAPI 기반 REST API 서버 개발

성과: 비동기 처리를 통한 동시 요청 처리 성능 개선 및 실시간 스트리밍 응답 구현

역할: FastAPI 서버 아키텍처 설계 및 LangGraph SDK 통합

기여:

- Agent 대화 API, 정보 추출 API, 배치 처리 API 개발

- 스레드 기반 대화 세션 관리 시스템 구현

- API 응답 속도 70% 개선 (비동기 처리 도입)

기술: FastAPI, LangGraph SDK, Uvicorn, Pydantic

4. 벡터 데이터베이스 및 검색 시스템 구축

성과: Qdrant 벡터 DB를 활용한 하이브리드(키워드 + 의미 기반 검색 시스템) 구축으로 관련 정보 검색 정확도 향상
역할: 벡터 임베딩 파이프라인 설계 및 검색 최적화
기여: 주제별 필터링 및 키워드 검색 기능 구현
기술: Qdrant Vector DB, OpenAI Embeddings, gRPC

5. AWS 클라우드 인프라 설계 및 CI/CD 구축

성과: Blue/Green 배포를 통한 무중단 서비스 구현 및 99.9% 가용성 달성

역할: AWS ECS Fargate 기반 마이크로서비스 아키텍처 설계 및 구축

기여:

- ECS Cluster, ALB, VPC, Security Group 설정

- GitHub Actions 기반 CI/CD 파이프라인 구축

- 개발/운영 환경 분리 및 자동 배포 시스템 구현

기술: AWS ECS Fargate, ALB, VPC, ECR, GitHub Actions, Docker, Terraform

사용 기술 스택

Backend: Python, FastAPI, LangGraph, Crawl4ai

Frontend: Nextjs15(App router), shadcnUI, Copilotkit, tanstack-query, langchain/langgraph-sdk

AI: GPT-4.1, Claude, OpenAI Embeddings, TrustCall, LangSmith

Database: Qdrant Vector DB, PostgreSQL, Redis

Infrastructure: AWS ECS Fargate, ALB, VPC, ECR, CloudWatch

DevOps: Docker, GitHub Actions, Terraform, Blue/Green Deployment

Monitoring: LangSmith Tracing, CloudWatch Logs



투썸월드

2019.03 - 2025.02 (6년) | 정규직

프로젝트명: 공맵 - 공부의 길을 이어주는 멘토링 플랫폼

2023.04 - 2023.08

- 웹사이트: <https://gongmap.com>

- 프로젝트 개요:

- 해외 교육 과정(SAT, IB, AP, A-Level) 준비생을 위한 온라인 멘토링 서비스

- 교과 과목 멘토링, 에세이 첨삭, 입시 컨설팅 제공

- 진학 희망 대학 선배와의 직접 멘토링 연결 서비스

- 담당 업무 및 기여:

- 플랫폼 기획 및 설계: UI/UX 중심의 서비스 구조 설계

- 멘토링 매칭 알고리즘 개발: 학습 요구사항과 멘토 전문성 기반 매칭 시스템 구현

- 입시 정보 및 리소스 제공: 최신 입시 정보, 대학 리소스, 에세이 작성 가이드 등 통합 제공

- 개발 환경:

- 프론트엔드: TypeScript

- 디자인 시스템: Vuetify, Material Design System

- 데이터 관리: @tanstack/vue-query, Pinia, Vuex

- 데이터베이스: MongoDB

- 클라우드 서비스: AWS

RAG 비자 챗봇 시스템 개발

2024.02 - 2024.04

- 비자문서 마크다운 포맷으로 전처리
- 벡터데이터베이스 구축
- hybrid search(keyword + semantic)
 - BM25 알고리즘 기반 키워드 검색과 임베딩 기반 시맨틱 검색을 결합한 하이브리드 검색 아키텍처 구축
 - 검색 정확도 향상을 위한 다단계 검색 파이프라인 구현
 1. 키워드 검색으로 1차 후보군 추출 (Recall 최적화)
 2. 시맨틱 검색으로 연관성 높은 문서 식별 (Precision 최적화)
 3. Cross-encoder 기반 Reranker로 최종 순위 결정
- 검색 성능 최적화
 - 문서 전처리 및 인덱싱 전략 수립
 - 문서 청킹 크기와 오버랩 최적화 (chunk size: 512, overlap: 50)
 - 메타데이터 추출 및 인덱싱으로 검색 필터링 강화
 - 검색 속도 개선
 - 벡터 인덱스 ANN(Approximate Nearest Neighbor) 알고리즘 튜닝
 - 캐싱 레이어 도입으로 자주 사용되는 쿼리 응답 시간 80% 단축
- 검색 품질 관리 시스템 구현
 - 사용자 피드백 기반 검색 결과 평가 시스템 구축
 - Langsmith을 활용한 검색 결과 트레이싱 및 모니터링
 - A/B 테스트를 통한 검색 파라미터 최적화
 - BM25와 시맨틱 검색 가중치 조정
 - 임계값(threshold) 설정으로 검색 정확도 향상

크롤링 & 데이터 수집 및 처리

2024.06 - 2024.07

- 주요 업무 및 담당 역할:
 - 크롤링 및 수집된 데이터에 대한 전처리, 분류, 검증, 번역 시스템 개발
 - 로깅/모니터링 시스템 개발

비동기 처리 도입으로 크롤링 속도 300% 향상

데이터 검증 파이프라인 구축으로 데이터 정확도 95% 이상 달성

- 확장 가능한 마이크로서비스 아키텍처 설계 및 구현
 - 컴포넌트 기반 모듈러 아키텍처 구축
 - 책임 분리를 통한 유지보수성 향상
 - 의존성 주입을 통한 느슨한 결합도 구현
- 대규모 데이터 수집 파이프라인 개발
 - 비동기 처리 기반의 고성능 크롤링 시스템 구축
 - 멀티스레딩을 활용한 병렬 처리 구현
 - 실시간 데이터 스트리밍 처리
- 데이터 품질 관리 시스템 구축
 - 다국어 번역 및 데이터 검증 파이프라인 구현
 - 데이터 정합성 검증 자동화

- 블랙리스트 필터링 시스템 개발
- 실시간 모니터링 및 로깅 시스템 구현
 - JSONL 기반 구조화된 로깅 시스템 구축
 - Slack/Email 기반 실시간 알림 시스템 개발
 - 성능 메트릭 수집 및 분석 대시보드 구현
- 데이터 처리 자동화 시스템 개발
 - 문서 전처리 및 정규화
 - 메타데이터 추출 및 인덱싱
 - 데이터 중복 제거 및 병합
 - 자동 카테고리 분류 시스템

AI 면접 데모개발 및 AI 이력서 기반 자기소개서 검색 기능개발

2024.11 - 2024.11

- 주요 업무 및 담당 역할:
 - 음성을 통해서 선택한 직군에 맞춘 AI 면접진행 PoC 개발
 - 자신의 이력서를 업로드하여 AI로 자기소개서 검색해주는 서비스
- AI 서비스 개발을 통해 서비스의 경쟁력 향상
- Openai realtime api / Livekit Agent
- 면접 진행한 대화내용을 기반으로 점수평가 crewai

백오피스 애플리케이션 개발

2024.09 - 2024.11

- 주요 업무 및 담당 역할:
 - Next.js 15 기반의 백오피스 웹 애플리케이션 구축
 - 다국어 채용 공고 관리 시스템 개발
 - AI 기반 자동 번역 시스템 구현 (Claude 3 Sonnet 모델 활용)

한국어 교육 플랫폼 개발

2023.09 - 2024.01

- 주요 업무 및 담당 역할:
 - 웹 페이지 UI 개발: Tailwindcss와 shadcnUI를 활용한 모던하고 반응형 디자인 구현
 - API 연동 개발: RESTful API를 활용한 강의 콘텐츠 제공 및 사용자 진행 상황 추적 기능 구현
 - 한국어 콘텐츠를 위한 프롬프트 R&D: OpenAI, Gemini 등 AI 기술을 활용한 맞춤형 학습 콘텐츠 생성
- 개발 환경:
 - 프론트엔드: NextJS 14(App Router), ReactJS, TypeScript
 - 디자인 시스템: Tailwindcss, shadenUI
 - 데이터 관리: @tanstack/react-query, @tanstack/react-table
- 프로젝트 진행 인원: 15명
- 주요 성과:
 - 페이지 로딩 속도 40% 개선 (Lighthouse 성능 점수 65점 91점)
 - 회사 내부 사정으로 프로젝트 중단



투미유

2017.10 - 2018.12 (1년 3개월) | 정규직

IOS 앱 개발 / 백엔드 개발

2017.10 - 2018.12

- 앱스토어 링크: [투덱 - 영어회화 더빙 스피킹 웨도잉]
- 웹사이트: <https://www.2meu.me>
- 개발 환경 및 사용 기술:
 - 버전 관리 및 배포: Bitbucket, AWS (EC2, ELB, CloudFront, S3, RDS), Docker
 - 서버 및 프레임워크: Ubuntu, Nginx, PHP 7.2, Laravel 5.6
 - 기술 스택: Firebase, Docker, Git, Redis, NodeJS, Swift 4.0, FFmpeg



에스콜닷컴

2014.12 - 2016.02 (1년 3개월) | 정규직

반응형 웹 기술 기반의 홈페이지 및 쇼핑몰 제작 플랫폼

2014.12 - 2016.02

- 주요 업무:
 - 프론트엔드 및 백엔드 개발 전담
 - 반응형 웹 빌더 "DUBUPLUS" 개발
 - 쇼핑몰 결제 시스템 및 관리자 모듈 개발
 - 검색엔진 최적화(SEO) 및 소셜미디어 통합 기능 구현
- 개발 환경:
 - 백엔드: PHP 5.3, 자체 프레임워크, MySQL
 - 프론트엔드: JavaScript, jQuery, AngularJS 1, HTML,

학력



대진대학교

2006.03 - 2013.08 | 졸업 | 철학과

스킬

Git

JavaScript

Python

MySQL

GitHub

Docker

TypeScript

Next.js

React.js

React

Node.js

HTML

수상/자격증/기타



지피터스 Llama index로 나만의 AI 프로젝트 만들기

2024.10 | 기타

- Livekit agent를 통해서 나만의 영어선생님 만들기
- [사례발표1](<https://www.gpters.org/chatbot/post/ai-roleplaying-conversation-application-qnoe9TQDzZv9lQM>)
- [사례발표2](<https://www.gpters.org/chatbot/post/ai-roleplaying-conversation-application-iF1DFPjzxXdvSlm>)



메타코드 데이터분석가 과정

2024.09 | 기타

- 탐색적 데이터분석 EDA
- 로우데이터에서 통계데이터 추출, SQL or Python -pandas
- 데이터시각화: 구글 루커스튜디오



해외연수프로그램 - 중소기업청이노비즈

2014.02 | 기타

독일, 오스트리아, 체코의 우수기업 및 기관 방문



웹접근성(KWAG2.0)가이드라인을 준수한 사이트 웹접근성 강화프로젝트

2013.08 | 기타

접근성(KWAG2.0)가이드라인을 준수한 사이트 웹접근성 강화프로젝트 접근성 위해한 부분 찾고 접근성에 맞춘 코딩하기 자바스크립트,제이쿼리로 인터랙티브 웹만들기



TeddyNote LangChain-OpenTutorial 오픈소스 프로젝트 참여

2025.02 | 기타

<https://github.com/LangChain-OpenTutorial/LangChain-OpenTutorial>

Langchain 튜토리얼 오픈소스 프로젝트에 참여해, Core Contributor로 등록됨.

언어



영어 | 일상 회화

링크

Github

<https://github.com/kofsitho87>

Medium Tech Blog

<https://medium.com/@kofsitho>

linkedin

<https://www.linkedin.com/in/kofsitho>