

송희웅 · Heewung Song

AI Product Engineer · 10년+ · 2026

반복되는 운영 업무를, 프로덕션 AI 시스템으로.

병원의 전화 업무를 AI가 실제로 처리하게 만들고, 그 시스템을 설계부터
운영까지 책임집니다. 같은 방식을 통화 분석과 사내 업무지원 AI로 넓혀
왔습니다.

병원 전화 Voice AI에서 시작해 통화 분석 및 평가 · 챗봇 고객상담 · AIU 사내 업무지원까지 운영 AI 제
품의 범위를 넓혀 왔습니다.

FOUR CHAPTERS · ONE PATTERN

- 01 병원 전화 Voice AI
거는 전화와 받는 전화를 하나의 시스템으로
- 02 통화 분석 및 평가
인·아웃바운드 통화 결과와 품질 분석
- 03 챗봇 고객상담
웹과 카카오휴 1차 응대
- 04 AIU 사내 업무지원
같은 방식을 동료의 업무로

620,000+

프로덕션 AI 통화 성공

4,000/일

일 평균 통화

300+

도입 병원

6

다국어 운영

키보드 ← → 또는 화면 클릭으로 다음 슬라이드

기술이 아니라, 업무 구조에서 시작합니다

무엇을 쓸지 고르기 전에, 누가 무엇을 반복하고 어떤 예외가 운영을 멈추게 하는지부터 정의합니다.

일하는 방식

01	업무 이해	반복 구간과 사람이 병목이 되는 지점을 먼저 찾습니다.
02	경계 설계	정책·권한·예외를 코드와 설정으로 고정해 모델의 추론과 분리합니다.
03	제품화	실제 도구·데이터·채널에 연결해 운영 가능한 상태까지 만듭니다.
04	운영 개선	관측과 평가 결과를 다음 설계의 근거로 되돌립니다.

프론트엔드·백엔드·인프라 경험 위에서 Multi-Agent, 실시간 음성 처리, 검색, LLM 평가를 하나의 제품 경계로 연결해 왔습니다.

Open Source · [LangChain-OpenTutorial Core Contributor \(2025.02\)](#)


소프트웨어 제품 개발 10년+ — 그 위에 올린 AI 제품 1년 6개월

2014 ↓ 2026

기간	회사 · 역할	주요 업무
2014.12 — 2016.02	에스콜닷컴 웹 개발자	반응형 웹 빌더·쇼핑몰 플랫폼의 프론트엔드와 백엔드 개발
2017.10 — 2018.12	투미유 소프트웨어 엔지니어	영어회화 학습 서비스의 iOS 앱·백엔드 개발과 AWS 인프라 운영
2019.03 — 2025.02	투썸월드 소프트웨어 엔지니어	교육·AI 웹 제품, 데이터 수집 파이프라인, RAG 비자 챗봇을 엔드투엔드 개발
2025.03 — 현재	와이즈에이아이 AI 엔지니어 / AI 프로젝트 팀장	Voice AI·통화 분석·고객상담·사내 업무지원 AI의 설계부터 운영까지 리드

END-TO-END PRODUCT SCOPE

사용자 접점에서 데이터·인프라까지 연결하고, 운영 결과를 다시 설계로 되돌립니다.




각 Chapter가 답하는 질문

네 Chapter는 각각 하나의 질문에 답하고, 그 답을 **코드와 운영으로 확인 가능한 설계 증거**로 뒷받침합니다. 행을 누르면 해당 Chapter로 이동합니다.

01	병원 전화 Voice AI CALL OPERATIONS 운영 검증 완료	병원의 전화 업무를 AI가 대신할 수 있는가? 병원별 설정 라우팅 · stage-before-commit 예약 · 공용 FIFO 상담원 연결	7 slides →
02	통화 분석 및 평가 ANALYZE THE CALLS 운영 중	인·아웃바운드 통화의 처리 결과와 품질을 어떻게 분석할 것인가? 통화 내용 복원 · 업무/통화 결과 분류 · 근거 기반 LLM 평가	8 slides →
03	챗봇 고객상담 STATEFUL SERVICE 제품 기반 구축	검색·개인정보·중단이 섞인 상담을 상태로 관리할 수 있는가? 결정론적 다섯 게이트 · pending_question 복귀	5 slides →
04	AIU 사내 업무지원 INTERNAL OPERATIONS 3주 MVP · 검증 중	같은 방식을 동료의 업무로 옮길 수 있는가? 범위 나눈 전문가 · SELECT-only 조회 · 실행 권한 분리	6 slides →


인/아웃바운드 Voice Call Agent

병원의 예약 확인·안내 전화를 자동 발신하고, 걸려오는 문의를 **예약 신청·병원 안내·상담원 연결**로 이어가는 실시간 Voice AI 시스템입니다.




전체 시스템 아키텍처

전화망, 실시간 미디어, Agent 실행, 업무 API와 후처리를 서로 다른 책임으로 분리했습니다.




녹음 · 관측 · 후처리 경로



Kafka가 실시간 경로와 분석의 경계입니다. 분석이 지연되거나 실패해도 전화 처리 경로는 계속 동작합니다.

LiveKit 기반 실시간 음성 처리

LiveKit Server는 미디어를 전달하고, 통화별 Agent job이 **STT·LLM·TTS와 Tool 실행**을 담당합니다.




한 통화 = Room + Job
통화 상태와 process를 서로 격리합니다.

SFU ≠ AI Runtime
STT·LLM·TTS는 SFU가 아니라 Agent container에서 실행됩니다.

Egress는 별도 경로
Room을 구독해 녹음하고 S3에 저장합니다.

안전한 Tool Calling 기반 예약 처리

LLM은 예약을 직접 확정하지 않습니다. 병원 정책을 확인하고, **조회된 일정과 환자의 동의가 일치할 때만** 예약 신청을 기록합니다.



Warm Transfer 기반 상담 연속성

AI가 모든 통화를 끝내는 것이 목표가 아닙니다. 사람의 판단이 필요한 순간에도 환자가 **같은 맥락으로 상담을 이어가게** 만듭니다.

병원 정책

같은 업무도 병원별로 AI 처리·상담원 연결·메모 접수 정책이 다릅니다.

자동화의 경계

사람의 확인과 판단이 필요한 요청은 AI가 완료한 것처럼 말하지 않습니다.

상담 맥락 유지

환자가 AI에게 설명한 내용을 상담원에게 다시 처음부터 말하지 않게 합니다.

AI → HUMAN FLOW

인·아웃바운드 공통 escalation

OUTBOUND

예약 확인·안내 중 예외 또는 상담 요청

INBOUND

문의·예약 요청 중 상담원 연결 필요

AI

AI 1차 상담

요청을 파악하고 병원 정책과 자동화 가능 범위를 확인합니다.

AI 처리 가능

같은 통화 안에서 계속 처리

사람 연결 필요

정책·예외·환자 요청에 따라 상담원에게 이관

Cold

즉시 전달

Warm

응답·맥락 확인

인간 상담원

환자 응대 계속

Leave Memo

연결 대상이 없거나 Warm 연결에 실패하면 응건과 연락 정보를 남깁니다.

→ 병원 후속 연락

실제 운영 통화

PROD · REDACTED

<> 시스템

오후 02:56:59

[WARM_TRANSFER_CALL: STATUS=STARTE

[상담원 번호]

<> 시스템

오후 02:56:59

[DIRECT_WARM_TRANSFER_CALL: STATUS=QUEUED, DETAILS={"queue_length":1}]

<> 시스템

오후 02:57:20

[WARM_TRANSFER_DTMF: DETAILS={"digit":"1"}]

<> 시스템

오후 02:57:21

[DIRECT_WARM_TRANSFER_CALL: STATUS=SUCCESS]

☞ AI가 아래 내용을 상담원에게 전달한 후, 상담원이 1번을 선택하여 상담을 진행했습니다.

"AI 인바운드 전화입니다. [환자] 께 걸려온 전화입니다. 고객과 AI와의 통화 내용을 브리핑하겠습니다. 고객이 예약 관련 안내를 듣고 상담원 연결을 기다리고 있습니다. 상담이 가능하시면 1번, 환자의 상담 요청 내용을 확인한 뒤 콜백이시거나 2번을 눌러주세요."

🔄 상담원 연결 전환

• 연결 요청 시각: 2026-08-14 14:56:59

• 상담원 연결: 성공

• 연결된 상담원 번호: [상담원 번호]

• 대기 시간: 22초

구현 증거 · 대기열 진입 → 상담원 DTMF 수락 → 연결 성공 → AI 브리핑 · 환자명과 전화번호는 완전히 마스킹했습니다.

COLD TRANSFER

빠르고 단순

SIP REFER로 즉시 전달하고 caller가 LiveKit Room을 떠나면서 AI 세션이 끝납니다. 상담 맥락 브리핑은 없습니다.

SIP REFER

→ Room 이탈

→ AI 종료

WARM TRANSFER

맥락을 유지

환자를 대기시키고 상담원 응답을 확인한 뒤, AI가 요청과 대화 맥락을 브리핑하고 연결 후 이탈합니다.

대기

→ 호출

→ 브리핑


→ 연결

→ AI 이탈

LiveKit 공식 Warm Transfer의 사용자 경험 단계를 참고하되, 현재 구현은 custom SingleRoomWarmTransferTask입니다.

상담원 연결 요청을 순서대로 처리합니다

인바운드와 아웃바운드 요청이 동시에 들어오면 병원별 **하나의 대기줄**에 세우고, 먼저 기다린 통화부터 상담원에게 연결합니다.



01
먼저 온 통화부터
요청이 들어온 순서를 그대로 유지합니다.

02
재시도해도 같은 자리
상담원 호출을 다시 해도 뒤로 가거나 새치기하지 않습니다.

03
끊어진 통화는 제거
환자가 통화를 종료하면 대기줄에서 빼고 다음 순서를 진행합니다.

04
한 회선에 한 통화
같은 상담원에게 여러 통화를 동시에 연결하지 않습니다.

연결 성공
첫 번째 통화가 빠지고 다음 통화가 연결 차례가 됩니다.

대기가 길어질 때
환자에게 계속 기다릴지 확인하며 통화를 유지합니다.

연결하지 못할 때
Leave Memo로 응건을 받아 병원의 후속 연락으로 이어갑니다.

성과와 배운 점

프로덕션에서 반복 통화를 운영하며, AI가 직접 끝낸 일과 사람에게 이어준 일을 **실제 결과**로 확인했습니다.

620,000+

인·아웃바운드 누적 성공 통화

4,000건/일

양방향 일 평균 통화

300개+

Voice AI 도입 병원

실제 인바운드 처리 결과 2026.08.13-26 · PROD

AI 단독 처리율

7.4%

상담원 연결이나 메모 접수 없이 AI가 끝까지 처리한 통화입니다.

예약 조회 요청 완료

91.0%

예약 취소 요청 완료

36.6%

예약 신청 요청 완료

16.8%

예약 변경 요청 완료

10.5%

업무별 숫자는 각 요청을 시도한 건 중 해당 흐름을 끝까지 처리한 비율입니다. 예약 신청은 신청 정보 기록이며, 변경·취소 완료도 실제 EMR 상태 변경 수치가 아닙니다.

운영하며 배운 세 가지

01

AI는 대화하고, 중요한 결정은 코드가 확인합니다

예약 시간·환자 동의·Tool 결과를 실제 데이터와 상태로 다시 확인했습니다.

02

AI가 해결하지 못해도 환자 요청은 남아야 합니다

Warm Transfer와 Leave Memo로 상담과 후속 연락이 끊기지 않게 했습니다.

03

통화를 단계별로 기록해 막힌 곳부터 고쳤습니다

본인확인·일정 안내·상담원 연결 중 멈춘 지점을 찾아 해당 구간부터 개선했습니다.

인/아웃바운드 통화 분석 및 평가

2026 · Kafka 기반 후처리·평가 파이프라인 · 설계·구현

대화 내용·시스템 이벤트·녹음을 결합해 **업무 처리 결과와 대화 품질**을 분석하고 운영 지표로 제공합니다.



장애 격리 실시간 통화와 분석을 Kafka로 분리해, 분석이 실패해도 실제 전화는 계속됩니다.

상세 범위 다음 장부터는 인바운드 분석 v2를 중심으로 설명합니다. 아웃바운드는 별도 파이프라인입니다.

상담원 연결 이후 통화 내용 복원

AI가 대화에서 빠진 이후의 환자·상담원 발화를 녹음에서 복원해, 한 통화의 전체 시간순 기록을 만듭니다.



녹음 준비 지연
준비되지 않았으면 가용성을 다시 확인합니다.

짧거나 조용한 오디오
분석 품질이 낮은 구간은 역지로 전사하지 않습니다.

상담원 발화 없음
상담 결과를 추정하지 않고 확인할 수 없음으로 남깁니다.

28개 규칙 기반 통화 분류

Developer 이벤트를 규칙으로 해석해 예약·정보·상담원·종료 활동을 **28개 항목으로 표시**합니다. 한 통화에서 여러 항목이 동시에 감지될 수 있습니다.

12

예약 업무

조회·신청·변경·취소의 완료·미완료·상담원 연결

1

정보 문의

병원 정보 조회와 응답 처리 성공

10

상담원 연결·메모

대기 초과·이탈·연결 성공·상담 요청 접수

5

통화 종료

인사 전·중·무입력·응답 지연·사용자 요청 종료

한 통화에서 동시에 감지

● 예약 변경 미완료 + ● 운영시간 내 상담 요청

MULTI-LABEL

Developer 이벤트

예약·연결·메모·종료 상태 기록

→

규칙 기반 분류

LLM 없이 이벤트 조건을 확인

→

28개 활동 플래그

기본값은 미감지, 조건 충족 시 감지

실제 Agent Admin 분류 화면

PROD · 개인·병원·통화 식별정보 제외

예약 신청 감지 후 중간 이탈 또는 생성 미완료, 또는 상담 요청 남기기 설정 시 분류

예약 변경 미완료 **해당없음**

예약 변경 감지 후 AI가 예약 변경 간 생성 완료

예약 변경 상담원 연결 **해당없음**

예약 변경 감지 후 상담원 물린만 시도 및 연결 성공

예약 취소 미완료 **해당없음**

예약 취소 감지 후 중간 이탈 또는 생성 미완료, 또는 상담 요청 남기기 설정 시 분류

예약 취소 완료 **해당없음**

예약 취소 감지 후 AI가 예약 취소 간 생성 완료

예약 취소 상담원 연결 **해당없음**

예약 취소 감지 후 상담원 물린만 시도 및 연결 성공

정보문의

정보 문의 완료 **해당없음**

에이전트가 factdata를 조회하여 환자에게 응답

상담원

상담원 연결 대기 시간 초과 **해당없음**

상담원 연결 시도 실패: 대기 시간 초과로 연결되지 않음

직접 연결 대기 시간 초과 **해당없음**

직접 연결 시도 실패: 대기 시간 초과로 연결되지 않음

운영시간 외 직접 연결 성공 **해당없음**

운영시간 외 환자의 직접 연결 요청으로 연결 성공

운영시간 내 상담원 연결 성공 **해당없음**

운영시간 내 환자의 상담원 연결 요청으로 연결 성공

운영시간 외 상담 요청 **해당없음**

운영시간 외 환자가 상담 의사를 표현하여 상담 요청 접수

상담원 연결 대기 중 이탈 **해당없음**

상담원 연결 대기 상태에서 환자가 통화를 먼저 종료

직접 연결 대기 중 이탈 **해당없음**

직접(간접) 연결 대기 상태에서 환자가 통화를 먼저 종료

운영시간 내 직접 연결 성공 **해당없음**

운영시간 내 환자의 직접 연결 요청으로 연결 성공

운영시간 외 상담원 연결 성공 **해당없음**

운영시간 외 환자의 상담원 연결 요청으로 연결 성공

운영시간 내 상담 요청 **감지됨**

운영시간 내 환자가 상담 의사를 표현하여 상담 요청 접수

기타

인사말 시작 전 통화 종료 **해당없음**

인사말이 시작되기 전에 통화가 종료됨

인사말 중 통화 종료 **해당없음**

인사말 중 통화 종료

인사말 완료 후 DTMF 또는 업무 요청 없이 발언자가 통화 종료

통화 지연으로 시스템 종료 **해당없음**

환자의 발화 없이 일정 시간 초과하여 시스템에 의해 통화 종료


사용자 요청으로 종료 **해당없음**

환자가 명확하게 종료 의사를 표현하고 통화 종료

상단 통화·환자·병원 정보와 내부 통화 ID를 완전히 제외한 카드 영역

업무별 처리 결과와 통화 결과 분류

한 통화 안의 여러 업무 결과는 각각 기록하고, 통화 전체의 대표 결과는 **하나만** 남겨 중복 집계를 막습니다.



요청별로 따로 기록

하나의 상담원 연결을 앞선 모든 요청에 중복 반영하지 않습니다.



종료 원인을 구분

시스템이 종료한 통화를 환자 이탈로 계산하지 않습니다.



실패 지점을 구분

본인 확인 전 중단과 확인 후 실패를 같은 원인으로 계산하지 않습니다.

LLM 기반 대화 품질 평가

업무 처리 결과는 규칙으로 유지하고, 요청 의도·응답 품질처럼 **해석이 필요한 항목만** 실제 대화 근거를 요구해 LLM으로 평가합니다.



LLM이 평가하는 항목

SEMANTIC QA



요청 의도

환자가 무엇을 원했는가



응답 품질

질문에 적절하게 답했는가



환자 경험

불편함과 만족 신호가 있었는가



긴급·미지원 요청

추가 검토가 필요한가



환자 발화가 없으면 평가하지 않음

LLM을 호출하지 않고 평가 제외로 기록합니다.



근거 검증 사례

EVIDENCE

● 모든 평가 = 신뢰도 + 근거 turn



환자 발화

목요일 오후를 요청한 근거 없음

USER TURN - valid for patient intent



AI 발화

“목요일 오후 가능합니다”

ASSISTANT TURN - response evidence only

✕ 잘못된 평가

환자는 목요일 오후를 원함

✓ 적용 규칙

환자 의도는 환자 발화만 근거로 사용



업무 결과는 코드가 유지

LLM 평가가 처리 결과를 덮어쓰지 않습니다.



근거 없으면 확인할 수 없음

상담원 발화가 없으면 상담 결과를 추정하지 않습니다.



민감한 평가 결과 분리

임상·QA 소견은 downstream Kafka에서 제외하고, Langfuse에는 원문 없이 집계 점수만 보냅니다.

운영 지표로 현황 확인

응대·셀프 처리·예약·상담원 연결과 초기이탈을 같은 기간에서 비교해 **운영 상태의 변화를 먼저 확인**합니다.

인바운드 운영 현황

2026-08-24 · PROD · inbound_daily_v4

Prodinboundtotal scope

전환율 재집계실시간 롬업체별 분석콜 내역 보기

인바운드 운영 현황

DB에 저장된 일별 전환율 메트릭을 기준으로 선택 기간의 운영 상태, 비교 기간 대비 변화, 초기이탈 신호를 확인합니다.

날짜 범위 선택

최신 기준일
2026-08-24

직전 기준일
2026-08-23

최근 저장일
14개

메트릭 버전
inbound_daily_v4

전체 통화
2,750

저장된 전체 inbound call

+2,640건

전체 응대 성공률
64.5%

834 / 1,294

+33.2%p

셀프 처리율
47.4%

614 / 1,294

+17.4%p

예약 생성 전환율
37.4%

76 / 203

-4.2%p

상담원 연결 성공률
87.9%

283 / 322

+54.6%p

인사말 시작 전 종료
4.0%

52 / 1,294

-3.5%p

인사말 중 종료
30.1%

390 / 1,294

-4.9%p

인사 완료 후 무입력 종료
10.1%

131 / 1,294

-8.6%p

전환/응대 추세

실제 PROD 집계 화면 · 비식별 상단 영역만 사용

이 화면에서 확인하는 것

비율 하나가 아니라 운영 흐름 전체를 봅니다.

응대와 셀프 처리

AI가 통화를 받고 사람 개입 없이 마친 흐름을 함께 봅시다.

예약과 상담원 연결

자동 처리와 사람 연결이 실제 업무 결과로 이어지는지
확인합니다.

 초기이탈 구간

다음 단계 · 지표가 움직인 이유는 통화 분석 화면에서 확인합니다.

통화 분석으로 문제 진단

통화를 하나의 결과와 업무별 시도로 나눠 어디에서 실패했고 다음 개선을 누가 맡아야 하는지 확인합니다.



인바운드 콜 분석 진단실

2026-08-13~26 · PROD · Analytics v2.1.0

Call analytics v2 · PROD · 분석 완료 기준

전체 콜 내역

인바운드 콜 분석 진단실

통화를 시도 단위로 분해해 어디에서 손실이 발생했고, 어떤 팀이 다음 개선을 맡아야 하는지 추적합니다.

분석 기간

2026.08.13 ~ 2026.08.26

환경

PROD

기분값

일부 원본 통화의 v2 분석이 아직 완료되지 않았습니다.

분석 커버리지

100%

20,626 / 20,627건

분석 완료 통화

20,626건

2026-08-13~2026-08-26

분석 버전

2.1.0

current row만 집계

최신 계산

2026-08-26 15:23:56

Asia/Seoul

전체 통화

20,626건 기준

기간·환경 조건의 v2 분석 완료 통화 전체입니다. 인텐트 선택과 무관합니다.

통화 결과 분포

v2 분석 완료 통화의 상호배타 결과

분석 완료 20,626건



자체 처리율

사람 개입 없이 완료된 통화

7.4%

자체 처리 1,518건

실제 PROD 집계 화면 · 전화번호가 포함된 의미 진단 표는 캡처에서 제외

이 화면에서 확인하는 것

통화 결과와 업무 시도를 섞지 않고 봅니다.



통화 결과 분포

통화당 대표 결과 하나로 자체 처리·연결·메모·이탈을 비교합니다.



엄격한 자체 처리

업무 완료뿐 아니라 상담원 연결·메모가 없을 때만 인정합니다.



다음 개선 영역

환자 경험·병원 운영·백엔드·정책 설정 등 확인할 영역을 나눕니다.

단위 경계 · 통화 결과와 업무별 시도 결과는 합산하지 않습니다.

분석 결과를 운영 개선으로 연결

지표를 보는 데서 끝내지 않고, 문제를 찾은 뒤 **규칙을 검증하고** 과거 통화를 같은 기준으로 다시 계산합니다.



1. 현황 확인

처리율과 초기이탈
변화를 관찰



2. 문제 진단

통화 결과와 실패
지점을 분리



3. 규칙 개선

좁은 기간·병원
범위로 미리 검증



4. 과거 통화 재분석

버전별 결과를
다시 계산하고
비교



변경 전 미리 검증

기간·병원·통화 ID를 좁혀 실제 저장
없이 결과부터 확인합니다.



버전별 재계산

규칙이 바뀌면 LLM 호출 없이 과거
통화를 새 버전으로 다시 계산합니다.



평가 기준 조정

저장된 평가 원본을 유지하고 신뢰도
기준은 리포트 시점에 바꿉니다.




버전 보존 원칙

기존 결과를 덮어쓰지 않고 이전 버전과 새 버전을 함께 남겨, 규칙 변경 전후를 같은 통화로 비교합니다.

병원 고객상담 AI Agent

2025.03 - 2026.03 · 초기 상담 그래프와 서비스 경계 설계·주요 구현

웹·Kakao에서 환자 문의를 받고, 병원별 지식 안내부터 필요한 상담 절차까지 이어주는 **텍스트 기반 상담 챗봇**입니다.




LangGraph 기반 상담 시스템 아키텍처

정해진 규칙으로 먼저 처리하고, 필요한 문의만 상담 Agent와 도구 실행으로 연결합니다.




상태 기반 상담 흐름

개인정보 수집이 중간에 끼어들어도 **원래 질문과 이미 수집한 값**을 보존해 상담을 이어갑니다.



병원별 지식 검색과 근거 응답

같은 질문도 병원마다 답이 다르기 때문에 **병원과 질문 종류를 먼저 좁힌 뒤** 근거가 있는 답만 사용합니다.



데모가 아니라, 300개 병원에서 운영 중인 제품입니다

2025년 5월 출시 후 1년 3개월 — 실제 퍼널 수치와, 그 수치를 만든 설계 원칙입니다.

HOSPITALS

300+

도입 병원

IN PRODUCTION

1년 3개월

2025.05 – 현재

SESSIONS

7,464

누적 상담 시작 사용자

상담 시작부터 예약 완료까지

GA4 FUNNEL · ACTIVE USERS

챗봇 상담 시작

7,464명
100%예약 또는
상담원 연결2,987명
시작 대비 40%

예약 완료

812명
시작 대비 10.9%

10.9%

챗봇 상담을 시작한 사용자 10명 중 1명이 예약 완료까지 도달합니다. 상담의 40%는 예약·상담원 연결 단계로 이어집니다.

LESSON · 설계 교훈

LLM에게 처음부터 다 맡기지 않았습니다

질문 접수

모든 상담은 규칙 검사부터 통과합니다

HIT

규칙으로 즉시 응답

검증된 FAQ · 병원 운영시간·진료 Fact Data

MISS

그때만 생성형 상담

병원별 근거 검색 후 답변 생성

정답이 정해진 질문은 규칙이 답하고, 생성형 답변은 마지막 수단으로 남겼습니다.
병원이 300개로 늘어도 답변 품질이 흔들리지 않은 이유입니다.

사내 AX 프로젝트 – 동료의 반복 업무를 AI 코워커에게

2026.08 – 현재 · 설계·구축 · AX(AI Transformation): 반복 업무를 AI로 전환하는 사내 프로젝트

매뉴얼·통화 기록·운영 지표가 흩어져 있어, 답 하나 찾으려면 사내 시스템 여러 곳을 뒤져야 했습니다. **동료가 이미 쓰는 웹과 Slack**에서 질문 한 번으로 답을 받는 사내 AI 코워커를 만들었습니다.

AIU는 병원 AI 제품군(전화 AI · 통화 분석 · Agent Admin · 운영 도구)의 이름이고, OpenBot은 신원·권한·실행·감사를 담당하는 사내 Agent 플랫폼입니다. AIU 코워커는 OpenBot 위에서 동작합니다.

동료

웹 · Slack에서 질문



OpenBot

신원 확인 · 권한 · 감사



AIU 코워커

찾고, 근거로 답한다

운영 동료의 하루에서, 세 장면을 따라갑니다

09:30

어제 성과 확인

"어제 A병원 전화, 예약 전환 어땠어?"

10:00

문제 통화 검토

"예약 안 된 통화, 무슨 일이 있었지?"

14:00


병원 문의 응대

"이 화면 사용법을 물어보는데?"

스스로 실행하지 않습니다 · 지식은 읽기 전용, 데이터베이스는 SELECT만, 실행·권한·감사는 OpenBot이 소유합니다.

OpenBot 위에서, Supervisor가 네 전문 Agent를 지휘합니다

권한·감사·실행은 플랫폼(OpenBot)이 맡고, 도메인 지식과
답변은 **범위를 나눈 전문 Agent**가 맡는 Multi-Agent
구조입니다.



위임 — 범위를 나눈 전문 Agent 넷



Supervisor는 원본 문서를 직접 읽지 못합니다 — 위임만 하고, 전문 Agent의 답을 근거와 함께 돌려받습니다.

기술 스택

- TypeScript · Bun
- Deep Agents · LangGraph
- AG-UI
- GPT-5.6 Luna · Gemini
- MySQL
- Zod
- Slack
- Docker

09:30

"어제 A병원 아웃바운드 전화, 예약 전환 어땠어?"

운영 동료 · Slack

자연어로 물으면, 검증된 지표로 답합니다

왜 지표 계산을 코드가 소유하나

"전환율"이 무엇을 세는지가 질문마다 달라지면 대시보드와 답변이 어긋납니다. 계산 규칙을 코드에 고정해 **누가 언제 물어도 같은 숫자**가 나오게 했습니다.

- 한 전화번호가 여러 번 기록돼도 **최대 1건**으로만 집계합니다
- 메모 접수로 마무리된 통화는 **전환 실패**로 세지 않습니다

질문

병원과 날짜만 있으면 됩니다



코드가 소유한 조회

미리 검증된 SQL만 실행합니다



지표 답변

전환율 · 처리 결과 · 통화 목록

SELECT-only · 답변에는 이름·전화번호·대화 원문·녹음이 포함되지 않습니다.

답변 속에서 **예약이 안 된 통화**가 눈에 띄면 — 그대로 다음 장면으로 이어집니다 →

10:00

"그중 예약이 안 된 이 통화, 무슨 일이 있었는지 보여줘"

같은 대화에서 이어서 · 통화 ID 지정

무슨 일이 있었는지, 안전장치 안에서 확인합니다

환자와의 대화 원문은 민감 정보입니다. 검토는 하되 유출은 못 하도록 네 개의 안전장치를 코드로 강제했습니다.

○ 01 · 지정한 통화만

정확한 통화 ID 1~5건만 받습니다

"어제 통화 전부 보여줘" 같은 광범위 요청은 불가능합니다

○ 02 · 마스킹

이름·전화번호를 가리고 보여줍니다

한국 전화·주민등록번호·이메일 패턴을 치환합니다

○ 03 · 분량 제한

턴당 1,200자, 긴 대화는 앞뒤 60개만 읽습니다

● 04 · 재진술

최종 답변은 요약으로만 — 원문을 다시 노출하지 않습니다

대화 원문은 **untrusted data**로 취급합니다 — 통화 내용에 지시가 섞여 있어도 따르지 않습니다.

14:00

"병원에서 Agent Admin 화면 두 개가 뭐가 다른지 물어보는데, 어떻게 설명하지?"

운영 동료 · 웹

322개 매뉴얼에서 근거를 찾아, 화면까지 붙여 답합니다

한 AI가 다 읽지 않고, 제품별 전문 Agent 넷이 나눠 말합니다. 각자 자기 제품의 매뉴얼만 읽을 수 있어, 비슷한 화면이 많아도 답이 섞이지 않습니다.

받는 전화 담당

인바운드 Voice AI

거는 전화 담당

아웃바운드 Voice AI

Agent Admin 담당

통화 관리 화면

HQ·SVC 담당

본사·서비스 운영 도구

322개

5개 제품의 매뉴얼 문서 — 시작할 때 문서 수·접근 정책·스크린샷 경로를 전부 검증합니다

접근할 수 없는 문서는 숨기되, "문서가 없다"고 단정해 답하지 않습니다.

실제 답변 화면

WEB

AIU Agent

Agent Admin에서 인바운드 분석 화면과 운영 현황 화면의 차이를 매뉴얼 근거와 함께 설명해줘. 관련 매뉴얼 스크린샷도 첨부해줘.

핵심 차이

구분	인바운드 운영 현황	인바운드 통화 분석 v2
목적	전체 인바운드 운영 성과와 기간별 추세 모니터링	통화 결과와 인텐트별 퍼널을 분석해 손실 원인 진단
매뉴/라우트	인바운드 에이전트 v1.0 > 운영 현황 /dashboard/inbound-agent	인바운드 에이전트 v1.0 > 통화 분석 v2 /dashboard/inbound-agent/analytics
주요 정보	전체 통화, 응대 성공, 셀프 처리, 예약 생성, Transfer, 초기 이탈, KPI, 추세, 주의 신호	분석 커버리지, 결과 분포, 자체 처리율, 책임 별 손실, 인텐트별 시도·완수율·퍼널, Semantic 오귀인 후보
기본 분석 단위	저장된 일별 지표와 기간 집계	통화 단위 결과 및 인텐트 시도(attempt) 단위 퍼널
필터	날짜 범위와 직전 동일 기간 비교	날짜, 환경(env), 인텐트, Semantic 버전
적합한 질문	"기간별 운영 성과가 좋아졌는가?"	"어떤 결과에서 손실이 발생했고, 어느 인텐트가 원인인가?"

1. 운영 현황 화면

운영 현황은 운영 모니터링용 요약 화면입니다. 선택한 기간의 일별 지표와 직전 동일 기간을 비교하면서 다음과 같은 전체 성과를 확인합니다.

전체 인바운드 통화량

응대 성공

+ Ask anything

↑

WEB 비슷한 두 화면의 차이를 비교표로 구분해 답한 실제 사례입니다.

다음 단계 — 찾아주는 AI에서, 실행하는 AI로

지금 AIU 코워커는 **찾아서 답하는 읽기 전용**입니다. 실행을 맡길 기반은 이미 준비되어 있습니다.

NOW · 운영 중

묻고, 찾고, 답한다

- 매뉴얼 답변 · 통화 조회 · 통화 QA를 웹과 Slack에서
- 3주 만에 구축 — **5개 제품 · 322개 문서 · 4개 전문 Agent · 45개 계약 테스트**
- 읽기 전용 지식 · SELECT-only 조회 · 개인정보 마스킹



NEXT · 확장 방향 (진행 중)

같은 거버넌스 위에서, 반복 업무를 직접 수행한다

매뉴얼로 안내하던 반복 운영 업무를 AI가 직접 수행하는 AX 자동화로 확장합니다. 실행 기반은 OpenBot에 이미 있습니다.

- 정책 평가 → 감사 기록 → 실행 — 기록 없이 움직이는 경로가 없습니다
- Bot마다 격리된 컨테이너 브라우저로 화면 작업 수행
- 민감한 작업은 **사람이 승인**한 뒤에만 진행

확장 후에도 **AI가 임의로 실행하는 경로는 없습니다** — 모든 실행은 OpenBot의 정책·감사·사람 승인을 거칩니다.

ONE PATTERN · FOUR CHAPTERS

송희웅 · AI Product Engineer

AI를 가능성에서 프로덕션으로 옮기는 엔지니어입니다.

병원 전화 · 통화 분석 · 챗봇 상담 · 사내 업무지원 — 업무를 이해하고, 할 일
과 안 할 일을 정하고, 운영으로 증명합니다.

91.0%

예약 조회 요청 완료율

CH 01 · VOICE AI

28개

통화마다 감지하는 활동 플래그

CH 02 · CALL ANALYTICS

7,464명

누적 상담 시작 사용자

CH 03 · CHATBOT

322개

AI가 근거로 답하는 매뉴얼

CH 04 · AIU

✉ kofsitho@naver.com

🐙 GitHub

🌐 LinkedIn

📝 Tech Blog

📖 Medium